15 – Kostenkontrolle

KI-Training für Einsteiger

Selbststudium-Training: KI/LLMs sicher im Alltag nutzen

Version 1.0 • Stand: Oktober 2026

Datei: `15_kostenkontrolle.md`

https://github.com/mgunthner/AI-Training

Lizenz: CC BY-NC-SA 4.0

Inhaltsverzeichnis

15 – Kostenkontrolle **1**
Kernpunkte 1
Beispiel 1
Do / Don’t 2
Sicherheitshinweis 2
Mini-Checkliste 2
Übung (5 Min.) 2
Weiter 3

15 – Kostenkontrolle

Definition: Kostenkontrolle heißt: wissen, wie KI-Nutzung bezahlt wird (Free-Limits, Abo, API pro Token), wo Kosten entstehen und wie du sie im Griff behältst.

> **Merksatz:** Lange Eingaben, lange Antworten und Denken kosten – Limit oder Geld.

Kernpunkte

- **Drei Bezahlmodelle:**
  - **Free-Plan:** keine Geldkosten, aber Nutzungslimits (Nachrichten pro Zeitraum)
  - **Abo:** höhere Limits und mehr Funktionen gegen Monatspreis
  - **API:** Zahlung pro Token – eingehende wie ausgehende (Thema 02)
- **Kostentreiber:** großes Modell statt kleinem, lange Eingaben (gesamter Chatverlauf!), lange Antworten, Denkmodus (Thema 10), Datei- und Bildverarbeitung, Agenten-Schleifen (jeder Schritt kostet).
- **Sparen ohne Qualitätsverlust:** kleines Modell für Routine, kurzer Kontext nur mit Relevantem, neuer Chat statt Endlos-Verlauf, Antwortlänge begrenzen, Wiederholtes zusammenfassen statt neu einfügen.
- **Grundidee Caching und Batch:** Wiederholtes (z. B. gleicher Kontext) kann billiger zwischengespeichert und Sammelaufträge günstiger verarbeitet werden. Details hängen vom Anbieter ab.
- **Absichern:** Budget-/Ausgabenlimit setzen (wo möglich), Warnschwellen einrichten, für jede Nutzung ein eigenes Key mit eigenem Limit, Nutzung regelmäßig prüfen.
- **Limits statt Panik:** Im Free-Plan kostet Überschreiten des Limits Zeit, kein Geld. Trotzdem gilt: Denkmodus und große Modelle gezielt einsetzen, dann reicht das Limit länger.
- **Preise ändern sich:** Kontrolliere immer die aktuelle Preisseite deines Anbieters.

Beispiel

Du willst wöchentlich 20 Kundennachrichten fassen und antworten – Zahlen und Namen erfunden:

Variante	Ansatz	Tendenz
1	Ein Chat, alle 20 Mails nacheinander im Denkmodus	Verlauf wächst, jeder Aufruf rechnet alles mit, Limit schnell leer
2	Pro Mail ein neuer Chat, kleines Modell, kurzer Prompt	Minimaler Kontext, niedrige Kosten
3	Variante 2, aber Anweisung dauerhaft als System-Prompt	Tipparbeit gespart, Kosten ähnlich niedrig

Variante 2 oder 3 erledigt dieselbe Aufgabe für einen Bruchteil der Token – bei annähernd gleicher Qualität, weil die Aufgabe Routine ist.

Do / Don’t

Do	Don’t
Kleines Modell für Routineaufgaben	Alles mit dem größten Denkmodus machen
Neuen Chat starten, wenn der alte lang ist	Endlos-Chats führen und alles mitschleppen
Limits und Nutzung regelmäßig prüfen	Limits ignorieren und auf eine Rechnung hoffen
Key pro Projekt mit eigenem Limit	Einen Key für alles verwenden

Sicherheitshinweis

Überraschend hohe API-Kosten sind oft ein Hinweis auf einen geleakten API-Key. Prüfe bei unerwarteten Ausgaben zuerst die Nutzungshistorie und widerrufe im Zweifel den Key (Thema 14).

Mini-Checkliste

- ☐ Ich kenne die drei Bezahlmodelle und weiß, was meins kostet.
- ☐ Ich benenne drei Kostentreiber.
- ☐ Ich setze Limits und prüfe die Nutzung regelmäßig.
- ☐ Bei unerwarteten Kosten prüfe ich zuerst die Nutzungshistorie.

Übung (5 Min.)

Schätze grob: Eine Routineaufgabe (Mail zusammenfassen) braucht bei dir etwa 500 Token Ein- und 200 Token Ausgabe pro Vorgang. Bei 100 Vorgängen im Monat sind das rund 70.000 Token. Was würde sich am stärksten sparen: kürzerer Kontext, kürzere Antworten oder weniger Vorgänge? Rechne grob nach und nimm an, dass Ausgabe-Token teurer sind als Eingabe-Token.

Weiter

- Zusatzübungen: `02_zusatzuebungen/15_zusatzuebungen`
- Test: Test D (Technik & Kosten)
- Verwandt: 02 Token & Kontext, 03 Modellauswahl, 10 Denkaufwand, 14 API einfach erklärt

Stand: Oktober 2026