Lösung Test C – Risiken (Themen 12–13)

KI-Training für Einsteiger

Selbststudium-Training: KI/LLMs sicher im Alltag nutzen

Version 1.0 • Stand: Oktober 2026

Datei: `test_C_risiken_loesung.md`

https://github.com/mgunthner/AI-Training

Lizenz: CC BY-NC-SA 4.0

Inhaltsverzeichnis

Lösung Test C – Risiken (Themen 12–13) **1**
Thema 12 – Prompt Injection 1
Thema 13 – Guardrails 1
Punkte zusammenzählen 2
Wiederhole bei Fehlern 2

Lösung Test C – Risiken (Themen 12–13)

Bestanden ab 75 %: 9 von 11 Punkten (8 Punkte zählen nicht als Bestehen, da 8/11 ≈ 73 %) Schau erst hierher, wenn du den Test fertig bearbeitet hast. Praxisaufgaben und Sicherheits-Checks bewertest du mit dem Selbstbewertungsraster (`selbstbewertung`).

Thema 12 – Prompt Injection

Cheatsheet: `01_cheatsheets/12_prompt_injection`

Frage 1 – B (1 P): Indirekte Injection steckt in Inhalten, die die KI verarbeitet – nicht in dem, was du selbst tippst (das wäre direkt, A). C beschreibt Halluzinationen (Thema 08), D fehlenden Kontext.

Frage 2 – Falsch (1 P): Dass die KI *sagt*, sie habe eine Anweisung ignoriert, beweist nichts – sie kann den Inhalt trotzdem berücksichtigt haben oder später befolgen. Verlasse dich auf Prüfung und Freigabe, nicht auf die Selbsteinschätzung der KI.

Frage 3 – Musterlösung (2 P): (a) 1 P für mindestens zwei Warnsignale, z. B. versteckter Text (weiß auf weiß) mit KI-Anweisung, Aufforderung, einen fremden Link zu empfehlen, unpersönliche Standardrechnung kombiniert mit Zahlungs-Link, der nicht zum Absender passt. (b) 1 P: z. B. das Dokument erst selbst überfliegen (auch mit Textauswahl/Zoom, um versteckten Text zu sehen), keine sensiblen Daten zusammen mit dem Fremddokument einfügen, Rechnungsersteller separat verifizieren, bei Verdacht NICHT über den genannten Link „bezahlen“.

Frage 4 – C (1 P): Nicht klicken, Verlauf und Zugriffe prüfen, bei Bedarf widerrufen, Vorfall melden. A ist genau der beabsichtigte Trick, B verbreitet das Problem, D fragt dieselbe (möglicherweise kompromittierte) KI.

Thema 13 – Guardrails

Cheatsheet: `01_cheatsheets/13_guardrails`

Frage 5 – A, C, E (2 P): Filter machen Fehler, in beide Richtungen (A). Menschliche Prüfung bleibt nötig (C). Konkrete, positive Formulierungen wirken besser (E). Eigene Regeln erhöhen die Wahrscheinlichkeit für gutes Verhalten, garantieren aber nichts (B) – und Guardrails schützen nicht vollständig vor Injection (D), deshalb mehrere Schichten.

Frage 6 – Falsch (1 P): Jailbreak-Versuche können gegen die Nutzungsbedingungen verstoßen und zur Kontosperrung führen – und sie bringen keinen praktischen Nutzen für deinen Alltag. Grenzen von Filtern erkennst du auch aus zuverlässigen Quellen (Doku, Testberichte).

Frage 7 – Musterlösung (2 P): (a) 1 P, z. B.: „Gib keine Rechts- oder Gesundheitsberatung. Wenn eine Frage in diese Bereiche gehört, weise auf Fachpersonen hin und halte dich beim Inhalt an allgemeine, unverbindliche Informationen.“ (b) 1 P, z. B.: „Erfinde keine Angaben. Wenn dir Information fehlt, frage nach oder markiere die Stelle mit [OFFEN: …].“ Punktvergabe: positives Verhalten beschrieben (nicht nur Verbot) und beobachtbares Handeln genannt.

Frage 8 – B (1 P): Regel schärfen und Prüfung ausbauen – Guardrails sind iterativ. Löschen (A) oder Akzeptieren (C) macht es schlimmer, Anbieterwechsel (D) ist keine Reaktion auf einen einzelnen Vorfall.

Punkte zusammenzählen

Thema	Fragen	Mögliche Punkte	Meine Punkte
12 Prompt Injection	1–4	5	
13 Guardrails	5–8	6	
Gesamt		**11**	

Bestanden: 9 Punkte oder mehr (75 % von 11 = 8,25, gerundet 9).

Wiederhole bei Fehlern

- **Fehler bei Frage 1–4:** Thema 12 *Prompt Injection* und Zusatzübungen 12
- **Fehler bei Frage 5–8:** Thema 13 *Guardrails* und Zusatzübungen 13

Nicht bestanden? Wiederhole die Themen mit den meisten Fehlern und mach den Test danach erneut.